

ESSIN

M2 Data Engineer Cloud



Mise en place d'un système de prévision et de recommandation de stocks

Application au secteur agricole nord-américain

Réalisé par : Ryma DRISS
Encadrant : Yassine EL MAATAOUI
Année universitaire : 2025–2026

Résumé

Ce mémoire présente un système de prévision de la demande et de recommandation de stocks pour des produits agricoles vendus en Amérique du Nord. Le projet utilise dix années de factures, de janvier 2007 à décembre 2016. Le fichier initial contient 252 367 transactions. Après le filtrage du secteur agricole, de la région *Northern America*, des États-Unis et du Canada, 28 451 transactions concernant 32 produits sont conservées.

Les ventes sont enrichies avec des données Open Data : météo, inflation, croissance du PIB, taux d'intérêt et prix du blé, du maïs et du soja. Les données sont nettoyées, contrôlées, fusionnées puis préparées au niveau mensuel.

Trois modèles sont comparés à une méthode naïve : Ridge Regression, Random Forest et Gradient Boosting. L'entraînement utilise les années 2008 à 2014 et le test les années 2015 et 2016. Le Gradient Boosting obtient les meilleurs résultats avec une MAE de 19,657, un RMSE de 77,526, un R^2 de 0,874 et un WAPE de 35,85 %.

Le modèle final produit ensuite des prévisions pour les douze mois de 2017. Ces prévisions servent à calculer un stock de sécurité, un point de commande et un stock cible recommandé. Les résultats sont stockés dans SQLite puis préparés pour être analysés dans Power BI.

Mots-clés : prévision de la demande, stock, machine learning, Gradient Boosting, Data Engineering, Open Data, SQLite, Power BI.

Abstract

This report presents a demand forecasting and stock recommendation system for agricultural products sold in North America. The project uses ten years of invoice data, from January 2007 to December 2016. The original dataset contains 252,367 transactions. After filtering the agricultural sector, the *Northern America* region, the United States and Canada, 28,451 transactions related to 32 products are retained.

Sales data are enriched with Open Data : weather, inflation, GDP growth, interest rates and wheat, corn and soybean prices. The data are cleaned, checked, merged and prepared at a monthly level.

Three machine learning models are compared with a naïve baseline : Ridge Regression, Random Forest and Gradient Boosting. The models are trained on 2008–2014 and tested on 2015–2016. Gradient Boosting gives the best results with an MAE of 19.657, an RMSE of 77.526, an R^2 of 0.874 and a WAPE of 35.85 %.

The final model produces forecasts for the twelve months of 2017. These forecasts are used to calculate safety stock, a reorder point and a recommended target stock. The results are stored in SQLite and prepared for analysis in Power BI.

Keywords : demand forecasting, stock recommendation, machine learning, Gradient Boosting, Data Engineering, Open Data, SQLite, Power BI.

Table des matières

Résumé	i
Abstract	ii
Introduction générale	1
1 Contexte et objectifs	2
1.1 Contexte du projet	2
1.2 Objectifs	3
1.3 Périmètre	3
1.4 Notions utilisées dans le projet	3
2 Conception et réalisation du système	4
2.1 Données utilisées	4
2.1.1 Données internes	4
2.1.2 Données Open Data	5
2.2 Pipeline Data Engineering	5
2.2.1 Préparation et qualité des données	6
2.2.2 Automatisation et contrôles	7
2.3 Analyse exploratoire	7
2.3.1 Évolution et saisonnalité	7
2.3.2 Produits et pays	9
2.3.3 Lien avec les variables externes	10
2.4 Construction du modèle de prévision	10
2.4.1 Jeu de données du modèle	10
2.4.2 Variables et prétraitement	11
2.4.3 Séparation chronologique	11

2.4.4	Métriques	11
2.5	Prévision future et calcul du stock	12
2.6	Stockage et préparation BI	13
3	Résultats, visualisation et perspectives	14
3.1	Résultats du Machine Learning	14
3.1.1	Comparaison des modèles	14
3.1.2	Réel, prédit et erreurs	15
3.1.3	Importance des variables	16
3.1.4	Résultats par pays	17
3.2	Prévisions et recommandations de stock pour 2017	17
3.3	Visualisation avec Power BI	18
3.3.1	Vue générale des ventes	18
	Conclusion générale	20

Table des figures

1.1	Vue générale du projet de prévision et de recommandation de stock	2
2.1	Extrait des données de facturation utilisées dans le projet	4
2.2	Étapes principales du pipeline de données	6
2.3	Évolution mensuelle des quantités vendues	8
2.4	Répartition des ventes selon le mois de l'année	8
2.5	Produits les plus vendus sur la période étudiée	9
2.6	Répartition des quantités vendues par pays	9
2.7	Matrice de corrélation des principales variables numériques	10
2.8	Schéma de la base SQLite utilisée pour les résultats	13
3.1	Comparaison du RMSE des modèles testés	14
3.2	Comparaison entre les quantités réelles et prédites	15
3.3	Distribution des erreurs de prévision	16
3.4	Importance des variables du modèle Gradient Boosting	16
3.5	Prévisions de demande et recommandations de stock pour 2017	17
3.6	Produits avec les niveaux de stock recommandés les plus élevés	18
3.7	Vue générale des ventes dans Power BI	19

Liste des tableaux

2.1	Sources Open Data utilisées	5
2.2	Caractéristiques du dataset préparé	7
3.1	Performances sur la période 2015–2016	14

Introduction générale

La gestion des stocks dépend directement de la demande. Un stock trop faible peut créer une rupture. Un stock trop élevé augmente les coûts et immobilise des produits. Il est donc utile d'estimer les ventes futures avant de décider d'un niveau de stock.

Les factures permettent d'étudier les ventes passées. Dans le secteur agricole, d'autres informations peuvent aussi avoir un lien avec la demande, comme la météo, la situation économique ou le prix de certaines matières premières. Le projet combine donc les données internes avec plusieurs sources Open Data.

L'objectif est de construire une chaîne complète allant des données brutes jusqu'à une recommandation de stock. Le travail couvre la collecte, le nettoyage, l'analyse, le Machine Learning, les prévisions futures, le stockage dans SQLite et la visualisation dans Power BI.

La problématique retenue est la suivante :

Comment utiliser l'historique des ventes et des données externes pour prévoir la demande mensuelle et proposer des niveaux de stock adaptés ?

Chapitre 1

Contexte et objectifs

1.1 Contexte du projet

Le projet porte sur un historique de factures d'un groupe industriel. Le fichier contient plusieurs secteurs et plusieurs zones géographiques. L'étude concerne uniquement les produits du secteur agricole vendus aux États-Unis et au Canada.

L'objectif métier est de mieux comprendre les ventes passées pour estimer la demande future. Les prévisions servent ensuite à proposer des niveaux de stock.




FIGURE 1.1 – Vue générale du projet de prévision et de recommandation de stock

1.2 Objectifs

Le projet doit couvrir les étapes principales d'un projet Data Engineering et Machine Learning :

- préparer les données de ventes ;
- récupérer et intégrer les données externes ;
- analyser les ventes ;
- entraîner et comparer plusieurs modèles ;
- prévoir la demande future ;
- calculer des recommandations de stock ;
- stocker les résultats dans SQLite ;
- préparer les données pour Power BI.

1.3 Périmètre

L'étude utilise les ventes agricoles des États-Unis et du Canada entre janvier 2007 et décembre 2016. Les données sont préparées au niveau produit-pays-mois. Les années 2008 à 2014 servent à l'entraînement et les années 2015 et 2016 au test. Le modèle final est ensuite utilisé pour prévoir les douze mois de 2017.

Le projet ne contient pas l'historique du stock physique des entrepôts. Il ne prédit donc pas directement le stock disponible. Il prévoit la demande, puis calcule des recommandations de stock à partir de cette demande et des erreurs du modèle.

1.4 Notions utilisées dans le projet

La **prévision de la demande** consiste à estimer les quantités qui pourront être vendues dans le futur. Ici, la valeur à prévoir est la quantité mensuelle vendue pour un produit et un pays.

Le **Machine Learning** permet d'apprendre des relations à partir des données passées. Une méthode simple, appelée **modèle naïf**, utilise la vente du mois précédent comme prévision du mois suivant. Elle sert de référence pour comparer les autres modèles.

Trois modèles sont étudiés. La **Ridge Regression** est un modèle linéaire avec régularisation [6]. La **Random Forest** combine plusieurs arbres de décision [4]. Le **Gradient Boosting** construit les arbres les uns après les autres afin de corriger progressivement les erreurs [5].

Pour le stock, trois notions sont utilisées. Le **stock de sécurité** représente une marge ajoutée pour réduire le risque de rupture. Le **point de commande** indique le niveau à partir duquel une commande doit être déclenchée. Le **stock cible** correspond au niveau recommandé pour couvrir la demande prévue avec une marge de sécurité.

Power BI, ou BI, sert à présenter les résultats sous forme de tableaux de bord. Il est utilisé pour suivre les ventes, les performances du modèle, les prévisions et les recommandations de stock [10].

Chapitre 2

Conception et réalisation du système

2.1 Données utilisées

2.1.1 Données internes

La source principale est le fichier `Factures.csv`. Il contient 252 367 lignes et 38 colonnes. Les informations utiles concernent notamment la date, le produit, la quantité vendue, le montant, la région et le pays.

Trois filtres sont appliqués : le secteur agriculture, la région *Northern America* et les pays USA ou CAN. Après filtrage, 28 451 transactions concernant 32 produits sont conservées.

	extract_date	salesman_id	cust_type	cust_categor	customer_sir	cust_aging_y	geo_zone
318433	2019-01-20 0	AA00653	OEM	customer	2003-12-01 0	3.0	Europe
318591	2019-01-20 00:00:00.000		OEM	customer	2003-12-01 0	3.0	Europe
318778	2019-01-20 00:00:00.000		OEM	customer	2003-12-01 0	3.0	Europe
318786	2019-01-20 0	AA00487	distributor	customer	2002-01-01 0	4.0	Europe
318805	2019-01-20 00:00:00.000		OEM	customer	2003-12-01 0	3.0	Europe
318857	2019-01-20 0	Aaxxx	OEM	customer	1901-01-01 0	0.0	Europe
318916	2019-01-20 00:00:00.000		OEM	customer	1901-01-01 0	0.0	Europe
318963	2019-01-20 00:00:00.000		OEM	customer	2003-12-01 0	3.0	Europe
318973	2019-01-20 0	AA01115	OEM	customer	2004-09-06 0	2.0	Europe
319051	2019-01-20 0	AA01115	OEM	customer	2003-12-01 0	3.0	Europe
319057	2019-01-20 0	AA01115	OEM	customer	2003-12-01 0	3.0	Europe
319058	2019-01-20 0	AA01115	OEM	customer	2003-12-01 0	3.0	Europe
319105	2019-01-20 0	AA01115	OEM	customer	2003-12-01 0	3.0	Europe
319131	2019-01-20 0	AA01115	OEM	customer	1901-01-01 0	0.0	Europe
319138	2019-01-20 00:00:00.000		distributor	customer	2005-04-28 0	1.0	Asia
319139	2019-01-20 0	AA00653	OEM	customer	2003-12-01 0	3.0	Europe
319142	2019-01-20 0	AA00487	OEM	customer	2002-01-01 0	4.0	Europe

FIGURE 2.1 – Extrait des données de facturation utilisées dans le projet

2.1.2 Données Open Data

Les ventes sont enrichies avec des données externes issues de plusieurs sources.

TABLE 2.1 – Sources Open Data utilisées

Donnée	Source	Fréquence utilisée
Température et précipitations	Open-Meteo	Mensuelle
Inflation et croissance du PIB	Banque mondiale	Annuelle
Taux d'intérêt	FRED	Mensuelle
Prix du blé, du maïs et du soja	FRED	Mensuelle

Open-Meteo fournit les données météo [1]. L'inflation et la croissance du PIB viennent de la Banque mondiale [2]. Les taux d'intérêt et les prix agricoles viennent de FRED [3].

2.2 Pipeline Data Engineering

Le projet sépare les données selon leur étape de traitement : données brutes, données externes, historique, rejets, données préparées, tables Power BI, modèles, rapports et base SQLite.

Le pipeline suit les étapes suivantes :

1. collecter les données internes et externes ;
2. enregistrer les données brutes ;
3. nettoyer et contrôler les données ;
4. harmoniser les dates et les fréquences ;
5. fusionner les ventes avec les données externes ;
6. créer le dataset analytique ;
7. analyser les ventes ;
8. entraîner et évaluer les modèles ;
9. produire les prévisions futures ;
10. calculer les recommandations de stock ;
11. préparer SQLite et les tables Power BI.




FIGURE 2.2 – Étapes principales du pipeline de données

2.2.1 Préparation et qualité des données

Les dates sont converties avec pandas [8]. Une colonne `date_mois` représente le mois de chaque vente. Les données externes n'ont pas toutes la même fréquence. La météo est regroupée par pays et par mois. Les taux d'intérêt et les prix agricoles restent mensuels. L'inflation et le PIB sont annuels et sont répétés sur les mois de l'année.

Les ventes sont conservées avec une jointure à gauche. Le programme vérifie les dates, les quantités, les valeurs manquantes, le périmètre géographique et les identifiants. Une ligne peut être rejetée si sa date ou sa quantité est absente, si la quantité est inférieure ou égale à zéro ou si une donnée externe nécessaire manque. Dans l'exécution utilisée dans ce mémoire, aucune ligne n'a été rejetée.

TABLE 2.2 – Caractéristiques du dataset préparé

Indicateur	Valeur
Nombre de lignes	28 451
Nombre de colonnes	23
Période	2007–2016
Produits	32
Pays	2
Quantité totale vendue	142 628
Montant total pondéré	1 038 383
Lignes rejetées	0

2.2.2 Automatisation et contrôles

Le script `src/run_pipeline.py` exécute les notebooks dans le bon ordre avec `jupyter nbconvert`. Il crée aussi l’historique des données brutes, lance la création de la base et vérifie les principaux fichiers produits.

Les contrôles portent sur la présence des fichiers, les dimensions des datasets, les valeurs manquantes, l’unicité des identifiants, le respect du secteur et de la zone, l’ordre chronologique du train et du test, l’absence de prédictions négatives et le nombre attendu de prévisions futures.

2.3 Analyse exploratoire

Avant de construire le modèle, les ventes sont analysées pour comprendre leur évolution.

2.3.1 Évolution et saisonnalité

Les ventes mensuelles changent fortement entre 2007 et 2016. Elles augmentent après 2010, atteignent des niveaux élevés autour de 2012 et 2013, puis diminuent globalement à partir de 2014.




FIGURE 2.3 – Évolution mensuelle des quantités vendues

Les ventes sont aussi saisonnières. Elles sont généralement plus importantes entre juin et août. Juillet est le mois le plus actif sur l'ensemble de l'historique, alors qu'octobre et novembre sont plus faibles.




FIGURE 2.4 – Répartition des ventes selon le mois de l'année

Cette saisonnalité justifie l'utilisation du mois et des ventes passées dans le modèle.

2.3.2 Produits et pays

L'analyse par produit permet d'identifier les produits qui représentent la plus grande part des ventes. La figure 2.5 présente les produits les plus vendus sur la période étudiée.




FIGURE 2.5 – Produits les plus vendus sur la période étudiée

Les ventes sont concentrées sur une partie des produits. La catégorie liée aux équipements de récolte des céréales et du coton représente la plus grande partie des quantités vendues.

L'analyse par pays permet ensuite de voir comment les ventes sont réparties entre les États-Unis et le Canada. La figure 2.6 présente cette répartition.




FIGURE 2.6 – Répartition des quantités vendues par pays

Les États-Unis représentent environ 98 % des quantités vendues, contre environ 2 % pour le Canada.

2.3.3 Lien avec les variables externes

Une matrice de corrélation permet d'observer les relations entre les variables numériques.




FIGURE 2.7 – Matrice de corrélation des principales variables numériques

La quantité vendue et le montant des ventes sont fortement liés. Parmi les variables externes, certaines relations apparaissent avec la température ou le taux d'intérêt. Ces relations donnent une indication, mais une corrélation ne prouve pas qu'une variable cause directement la variation des ventes.

2.4 Construction du modèle de prévision

2.4.1 Jeu de données du modèle

Les transactions sont regroupées par produit, pays et mois. Lorsqu'un produit n'a aucune vente pendant un mois, la quantité est fixée à zéro.

Trois produits sont retirés car leur historique est trop court. Le dataset Machine Learning contient finalement 2 157 lignes, 25 colonnes, 29 produits et deux pays. Les mois sans vente représentent 53,59% des lignes.

Le problème est traité comme une régression supervisée. Pour un mois t , un produit p et un pays c , le modèle estime :

$$\hat{y}_{t,p,c} = f(X_{t,p,c}) \quad (2.1)$$

où $X_{t,p,c}$ contient uniquement les informations disponibles avant le mois à prévoir.

2.4.2 Variables et prétraitement

Les variables utilisées sont l'année, le mois, les ventes passées, la moyenne des trois derniers mois, la vente observée douze mois auparavant, le produit, la catégorie, le pays et les données météo, économiques et agricoles.

Les variables historiques sont décalées afin d'éviter d'utiliser une information future pour prévoir le passé.

Les variables numériques sont mises à l'échelle avec `StandardScaler`. Les variables catégorielles sont transformées avec un encodage one-hot. Le prétraitement et le modèle sont regroupés dans un pipeline Scikit-learn [7].

2.4.3 Séparation chronologique

Les données ne sont pas mélangées au hasard. La séparation suit le temps :

- entraînement : janvier 2008 à décembre 2014, soit 1 672 observations ;
- test : janvier 2015 à décembre 2016, soit 485 observations.

Cette séparation permet de tester le modèle sur une période située après la période d'apprentissage.

2.4.4 Métriques

Quatre métriques sont utilisées.

MAE :

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i| \quad (2.2)$$

RMSE :

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2} \quad (2.3)$$

R^2 :

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad (2.4)$$

WAPE :

$$WAPE = \frac{\sum_{i=1}^n |y_i - \hat{y}_i|}{\sum_{i=1}^n y_i} \times 100 \quad (2.5)$$

Le RMSE sert de critère principal. Le WAPE est utile ici car beaucoup de mois ont une quantité réelle égale à zéro.

2.5 Prévision future et calcul du stock

Après l'évaluation, le meilleur modèle est réentraîné avec toutes les données disponibles entre 2008 et 2016. Le modèle final est enregistré dans `models/best_model_production.pkl`.

Les douze mois de 2017 sont prévus de manière récursive. Le modèle prévoit janvier à partir des dernières données de 2016. La prévision de janvier est ensuite ajoutée à l'historique pour prévoir février, puis le même principe est répété jusqu'à décembre.

Au total, 24 séries produit-pays sont prévues sur 12 mois, soit 288 prévisions. Les valeurs Open Data de 2017 ne sont pas disponibles dans le projet. Les dernières valeurs connues de décembre 2016 sont donc conservées pour toute l'année 2017.

Le stock de sécurité est calculé avec :

$$SS_{p,c} = \left\lceil z \times \sigma_{p,c} \times \sqrt{L} \right\rceil \quad (2.6)$$

avec $z = 1,65$ pour un niveau de service proche de 95 %, $\sigma_{p,c}$ l'écart-type des erreurs du modèle et $L = 1$ mois comme délai d'approvisionnement choisi pour le prototype.

Le point de commande est :

$$PC_{t,p,c} = \lceil \hat{y}_{t,p,c} \times L + SS_{p,c} \rceil \quad (2.7)$$

Le stock cible est :

$$SC_{t,p,c} = \lceil \hat{y}_{t,p,c} + SS_{p,c} \rceil \quad (2.8)$$

Comme $L = 1$ mois dans le prototype, le point de commande et le stock cible peuvent avoir la même valeur.

2.6 Stockage et préparation BI

SQLite est utilisé pour stocker les résultats [9]. La base se trouve dans `data/database/stock_prediction.db`.

Le modèle de données contient trois dimensions principales : `dim_date`, `dim_product` et `dim_region`. Il contient aussi trois tables de faits principales : `fact_sales`, `fact_predictions` et `fact_stock_forecast`.




FIGURE 2.8 – Schéma de la base SQLite utilisée pour les résultats

La table `fact_sales` contient 1 331 lignes mensuelles. `fact_predictions` contient 485 prévisions de test. `fact_stock_forecast` contient 288 prévisions futures.

Les tables destinées à Power BI sont placées dans `data/powerbi`. Les dimensions sont reliées aux tables de faits par `date_id`, `product_id` et `region_id`. Les relations vont des dimensions vers les tables de faits. Les tables de faits ne sont pas reliées directement entre elles.

Chapitre 3

Résultats, visualisation et perspectives

3.1 Résultats du Machine Learning

3.1.1 Comparaison des modèles

TABLE 3.1 – Performances sur la période 2015–2016

Modèle	MAE	RMSE	R^2	WAPE
Gradient Boosting	19,657	77,526	0,874	35,85 %
Random Forest	20,004	78,101	0,872	36,48 %
Ridge Regression	23,511	82,329	0,857	42,88 %
Naïf M1	20,315	87,027	0,841	37,05 %

Le Gradient Boosting obtient le meilleur RMSE et le meilleur R^2 . Il est donc retenu pour la suite. Son RMSE est meilleur de 10,92 % par rapport au modèle naïf.




FIGURE 3.1 – Comparaison du RMSE des modèles testés

3.1.2 Réel, prédit et erreurs

Sur la période de test, la quantité réelle totale est de 26 594 unités. Le modèle prévoit environ 25 898,92 unités. Il sous-estime donc légèrement la demande totale.




FIGURE 3.2 – Comparaison entre les quantités réelles et prédites

Le modèle suit la tendance générale, mais certaines grandes quantités restent plus difficiles à prévoir.




FIGURE 3.3 – Distribution des erreurs de prévision

Le biais global est de -2,61 %. En moyenne, la différence réel moins prédit est d'environ 1,433 unité par observation.

3.1.3 Importance des variables




FIGURE 3.4 – Importance des variables du modèle Gradient Boosting

La vente du mois précédent est la variable la plus importante avec 88,53 %. Le prix du soja du mois précédent représente 2,61 %, la moyenne des trois derniers mois 2,04 % et la vente observée douze mois auparavant 1,14 %.

Les données externes ajoutent donc de l'information, mais l'historique récent des ventes reste l'élément principal du modèle.

3.1.4 Résultats par pays

Le WAPE est de 33,62 % pour les États-Unis et de 89,76 % pour le Canada. Cette différence vient surtout du faible volume de données canadiennes. Les résultats du Canada doivent donc être interprétés avec prudence.

3.2 Prévisions et recommandations de stock pour 2017




FIGURE 3.5 – Prévisions de demande et recommandations de stock pour 2017

La moissonneuse-batteuse et récolteuse de coton domine les prévisions futures. Sa demande annuelle prévue est de 10014,13 unités et son stock cible mensuel maximal atteint 1548 unités.




FIGURE 3.6 – Produits avec les niveaux de stock recommandés les plus élevés

Ces valeurs sont des recommandations basées sur la demande prévue et sur les erreurs du modèle. Elles ne représentent pas le stock réellement présent dans les entrepôts.

3.3 Visualisation avec Power BI

Power BI est utilisé pour présenter les résultats sous forme de tableaux de bord. L'objectif est de faciliter la lecture des ventes, l'analyse des produits, et les prévisions.

3.3.1 Vue générale des ventes

La page **Dashboard** donne une vue générale des ventes. Elle permet de suivre l'évolution du chiffre d'affaires et de comparer les résultats selon plusieurs critères.

Le graphique principal présente l'évolution du chiffre d'affaires total entre 2007 et 2016. Il permet de voir les années où le chiffre d'affaires augmente ou diminue.

La partie inférieure présente la répartition du chiffre d'affaires par pays ainsi que la part des différentes catégories de produits.

Des filtres sont également disponibles pour sélectionner l'année, le pays et la catégorie de produit. Ils permettent de modifier les graphiques selon les informations que l'utilisateur souhaite analyser.

Prévisions et stock 2017




FIGURE 3.7 – Vue générale des ventes dans Power BI

Conclusion générale

Ce projet met en place une chaîne complète allant des factures brutes jusqu'à une recommandation de stock. Les données sont filtrées, enrichies avec des données Open Data, nettoyées puis préparées pour l'analyse et le Machine Learning.

Plusieurs modèles sont comparés sur les années 2015 et 2016. Le Gradient Boosting obtient les meilleurs résultats avec un RMSE de 77,526, une MAE de 19,657, un R^2 de 0,874 et un WAPE de 35,85 %. Il améliore le RMSE du modèle naïf de 10,92 %.

Le modèle final produit 288 prévisions pour l'année 2017. Ces prévisions sont utilisées pour calculer un stock de sécurité, un point de commande et un stock cible. Les résultats sont stockés dans SQLite et préparés pour Power BI.

Le projet répond à l'objectif principal. Pour aller vers une utilisation réelle, les améliorations les plus importantes sont l'ajout de données récentes, du stock physique et des délais fournisseurs.

Bibliographie

- [1] Open-Meteo, *Historical Weather API Documentation*, <https://open-meteo.com/en/docs/historical-weather-api>, consulté en 2026.
- [2] World Bank, *World Bank Indicators API Documentation*, <https://datahelpdesk.worldbank.org/knowledgebase/topics/125589-developer-information>, consulté en 2026.
- [3] Federal Reserve Bank of St. Louis, *Federal Reserve Economic Data – FRED*, <https://fred.stlouisfed.org/>, consulté en 2026.
- [4] L. Breiman, “Random Forests”, *Machine Learning*, volume 45, pages 5–32, 2001.
- [5] J. H. Friedman, “Greedy Function Approximation : A Gradient Boosting Machine”, *The Annals of Statistics*, volume 29, numéro 5, pages 1189–1232, 2001.
- [6] A. E. Hoerl et R. W. Kennard, “Ridge Regression : Biased Estimation for Nonorthogonal Problems”, *Technometrics*, volume 12, numéro 1, pages 55–67, 1970.
- [7] Scikit-learn developers, *Scikit-learn User Guide*, https://scikit-learn.org/stable/user_guide.html, consulté en 2026.
- [8] pandas development team, *pandas Documentation*, <https://pandas.pydata.org/docs/>, consulté en 2026.
- [9] SQLite Consortium, *SQLite Documentation*, <https://www.sqlite.org/docs.html>, consulté en 2026.
- [10] Microsoft, *Power BI Documentation*, <https://learn.microsoft.com/power-bi/>, consulté en 2026.